ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc Lập - Tự Do - Hạnh Phúc

ĐỀ CƯƠNG CHI TIẾT

TÊN ĐỀ TÀI: ĐÁNH GIÁ THỰC NGHIỆM CHIẾN LƯỢC PHÂN ĐOẠN MÃ NGUỒN TRONG MÔ HÌNH RAG HỖ TRỢ ĐỐI SÁNH NĂNG LỰC ỨNG VIÊN

Cán bộ hướng dẫn: Ths Trần Thị Hồng Yến

Thời gian thực hiện: Từ ngày 07/09/2026 đến ngày 03/01/2027.

Sinh viên thực hiện:
Phạm Viết Quang Huy - 24520692
Nguyễn Ngọc Thu An - 24520063

Nội dung đề tài:*(Mô tả chi tiết mục tiêu, phạm vi, đối tượng, phương pháp thực hiện, kết quả mong đợi của đề tài)*

Mục tiêu nghiên cứu:

- Xây dựng hệ thống hỗ trợ đối sánh JD và hồ sơ GitHub ứng viên dựa trên minh chứng năng lực thực tế (Evidence-based JD–GitHub Matching), kết hợp mô hình ngôn ngữ lớn (LLM) để bóc tách yêu cầu kỹ năng từ JD và kiến trúc Retrieval-Augmented Generation (RAG) để đối sánh ngữ nghĩa với minh chứng của ứng viên, cho phép xếp hạng có thể giải thích được (explainable matching).

- Thực nghiệm so sánh định lượng ảnh hưởng của hai chiến lược phân đoạn mã nguồn (chunking strategy) – AST-based chunking (dùng Tree-sitter) và Fixed-size chunking – đến hiệu quả truy xuất bằng chứng kỹ thuật và chất lượng đối sánh kỹ năng (câu hỏi nghiên cứu trọng tâm RQ1).

- Xây dựng bộ tiêu chí đánh giá định lượng tương ứng với câu hỏi nghiên cứu đặt ra, kèm kiểm định ý nghĩa thống kê giữa hai chiến lược phân đoạn.

Đối tượng nghiên cứu:

- Bản mô tả công việc (JD) vị trí thực tập sinh/fresher trong lĩnh vực phát triển phần mềm.

- Mã nguồn và cấu trúc các kho lưu trữ (repository) GitHub công khai của ứng viên.

- Các chiến lược phân đoạn mã nguồn (AST-based chunking và fixed-size chunking) trong kiến trúc RAG hỗ trợ đối sánh ngữ nghĩa.

Phạm vi nghiên cứu:

- Về mặt học thuật và thực nghiệm: Nghiên cứu tập trung giải quyết RQ1 – đánh giá và so sánh định lượng ảnh hưởng của cấu trúc phân đoạn mã nguồn (AST-based so với Fixed-size) đến chất lượng truy xuất các đoạn mã minh chứng năng lực. Dữ liệu thực nghiệm giới hạn ở 25 JD chuẩn và 50 repository thuộc hai ngôn ngữ lập trình Java và TypeScript/JavaScript.

- Về mặt ứng dụng và kỹ thuật phần mềm: xây dựng hệ thống dưới dạng phiên bản sản phẩm khả dụng tối thiểu (MVP) phục vụ thu thập dữ liệu, tự động hóa luồng trích xuất – truy xuất – đối sánh, và minh họa giao diện đánh giá ứng viên cho nhà tuyển dụng. Các tính năng mở rộng như phát hiện gian lận mã nguồn (plagiarism detection) hoặc phân tích khoảng trống năng lực (Skill Gap Analysis) được định vị là mục tiêu mở rộng.

Phương pháp thực hiện:

- Thiết kế kiến trúc hệ thống 3 tầng: Trình diễn (giao diện web React), Nghiệp vụ & Xử lý RAG (Spring Boot kết hợp FastAPI), Dữ liệu (PostgreSQL tích hợp pgvector); đóng gói môi trường bằng Docker Compose và đặc tả API theo chuẩn Swagger/REST. Áp dụng cơ chế Caching (lưu đệm kết quả embedding và AST đã phân tích) và Async Worker (xử lý bất đồng bộ theo hàng đợi) để kiểm soát độ trễ khi xử lý các repository có kích thước lớn.

- Vận dụng cơ chế Phân bổ Lũy tiến (Progressive Disclosure) 3 cấp để xử lý repository: đọc metadata dự án, trích xuất README, và phân đoạn mã nguồn chi tiết.

- Cài đặt và so sánh hai chiến lược chunking: AST-based (dùng Tree-sitter, mỗi chunk là một function/method definition, có gắn Context Header gồm đường dẫn tệp tin, tên lớp/interface chứa hàm và các khai báo thư viện liên quan nhằm tránh mất ngữ cảnh khi tạo vector embedding) và Fixed-size (500 token/chunk, overlap 50 token), kèm cơ chế fallback sang line-based/indent-based khi Tree-sitter không phân tích được.

- Sử dụng mô hình nhúng bge-m3 để chuyển đổi các khối mã nguồn/văn bản thành vector, lưu trữ bằng PostgreSQL kết hợp pgvector, đối sánh bằng độ đo Cosine Similarity.

- Xây dựng tập dữ liệu thực nghiệm gồm 25 JD thu thập từ các nền tảng tuyển dụng thực tế (ITviec, TopCV) và 50 repository GitHub công khai (Java, JavaScript/TypeScript); gán nhãn ground truth theo thang 3 mức (0 – không liên quan, 1 – liên quan gián tiếp, 2 – minh chứng trực tiếp) theo Quy chuẩn gán nhãn (Annotation Guideline), kiểm định độ tin cậy liên đánh giá viên bằng hệ số Quadratic Weighted Cohen's Kappa (ngưỡng chấp nhận $\geq 0,7$).

- Đánh giá bằng các chỉ số truy xuất thông tin (Precision@5, Recall@5, F1@5, NDCG@5, MRR) và khung đánh giá Ragas (Faithfulness, Context Precision, Context Recall) kèm phân tích triệt tiêu (Ablation Study); kiểm định ý nghĩa thống kê bằng Wilcoxon Signed-Rank Test (hoặc Paired t-test) với mức ý nghĩa $\alpha = 0,05$.

- Xây dựng bộ tài liệu kỹ nghệ phần mềm đi kèm: Đặc tả yêu cầu phần mềm (SRS v1), Tài liệu thiết kế kỹ thuật (Tech Spec/ERD), Quy chuẩn gán nhãn dữ liệu (Annotation Guideline) và Kế hoạch/Bảng kịch bản kiểm thử (Test Plan & Test Cases).

Kết quả mong đợi:

- Hệ thống MVP hoàn chỉnh cho phân hệ Doanh nghiệp (đăng tải/bóc tách JD, nạp hồ sơ GitHub, hiển thị bảng xếp hạng ứng viên kèm minh chứng mã nguồn cụ thể), chạy thông suốt luồng end-to-end.

- Bộ số liệu thực nghiệm đầy đủ trả lời RQ1 (Precision@5, Recall@5, F1@5, NDCG@5, MRR, các chỉ số Ragas, kết quả kiểm định Wilcoxon và Ablation Study),

xác định chiến lược phân đoạn mã nguồn mang lại hiệu quả truy xuất minh chứng và chất lượng RAG tốt hơn.

- Bộ dữ liệu đã gán nhãn (25 JD, 50 repository) có thể tái sử dụng cho các nghiên cứu mở rộng.

- File báo cáo Đồ án 1 hoàn chỉnh theo đúng định dạng Phụ lục 1 UIT, kèm bộ slide thuyết trình và video demo hệ thống.

Hướng phát triển đề tài:

- RQ2: đo lường chất lượng xếp hạng ứng viên (NDCG@5, MRR) giữa hai chiến lược chunking.

- RQ3: đánh giá đánh đổi giữa hiệu quả truy xuất và chi phí tính toán (token, độ trễ) của AST-based chunking so với fixed-size chunking.

- Hoàn thiện phân hệ Sinh viên (khởi tạo hồ sơ qua GitHub OAuth, tìm vị trí thực tập theo kỹ năng) và module phân tích khoảng trống kỹ năng (Skill Gap Analysis).

- Bổ sung các giải pháp kỹ thuật đảm bảo chất lượng dữ liệu: phát hiện sao chép mã nguồn (Code Similarity Detection), phát hiện tài khoản bot, đánh giá độ trưởng thành repository.

- Mở rộng bộ dữ liệu lên quy mô đầy đủ (50 JD, 100 repository)

Kế hoạch thực hiện:*(Mô tả kế hoạch làm việc và phân công công việc cho từng sinh viên tham gia)*

Đề tài được thực hiện trong 18 tuần (01 học kỳ), chia thành 4 giai đoạn theo Kế hoạch chi tiết Đồ án 1, với 3 mốc kiểm tra Go/No-Go và phân công cụ thể giữa hai sinh viên Phạm Viết Quang Huy và Nguyễn Ngọc Thu An:

Giai đoạn 1 – Khởi tạo, Yêu cầu & Thiết kế (Tuần 1–4):

- Tuần 1: Đăng ký đề tài, nộp Đề cương chi tiết.

- Tuần 2: Khảo sát tài liệu quốc tế (cAST, CodeCV); chốt câu hỏi nghiên cứu (RQ1) và bộ chỉ số đánh giá (Cả nhóm).

- Tuần 3: Soạn tài liệu đặc tả yêu cầu phần mềm SRS v1 (Thu An); thiết kế kiến trúc 3 tầng và CSDL pgvector – Tech Spec/ERD (Quang Huy).

- Tuần 4: Soạn Quy chuẩn gán nhãn – Annotation Guideline v1 (Thu An); dựng khung code skeleton Spring Boot, FastAPI, Docker Compose (Quang Huy).

Giai đoạn 2 – Thu thập dữ liệu & Phân đoạn mã nguồn (Tuần 5–9):

- Tuần 5: Chạy thử nghiệm Pilot (5 JD + 10 repo), gán nhãn độc lập, đo Cohen's Kappa (Cả nhóm). Checkpoint 1 (Go/No-Go): Kappa pilot ≥ 0,7 – nếu không đạt, họp sửa guideline.

- Tuần 6: Cài đặt parser Tree-sitter bóc tách AST (Java/JS) kèm tạo Context Header (đường dẫn file + tên lớp) (Quang Huy).

- Tuần 7: Cài đặt cơ chế Fallback & Fixed-size chunking (Quang Huy); thu thập song song dataset 25 JD & 50 repo (Thu An).

- Tuần 8: Tích hợp Embedding BGE-M3, lưu vector vào pgvector và cài đặt cơ chế Caching + Async Worker để kiểm soát độ trễ (Quang Huy); làm sạch, tiền xử lý dataset (Thu An).

- Tuần 9: Hoàn tất 100% gán nhãn Ground Truth trên 25 JD & 50 repo (Thu An & Quang Huy). Checkpoint 2 (Go/No-Go): 100% dataset gán nhãn xong – nếu chưa đạt, tuần 10 ưu tiên bù trước khi nối RAG.

Giai đoạn 3 – Xây dựng hệ thống & Thực nghiệm (Tuần 10–14):

- Tuần 10: Xây dựng Web MVP phân hệ Doanh nghiệp (đăng JD, nạp GitHub, hiển thị bằng chứng code và điểm số) – Thu An phụ trách giao diện, Quang Huy kết nối API.

- Tuần 11: Tích hợp Matching Engine (LLM Reasoning), hiển thị bằng chứng code và điểm số cho phân hệ Doanh nghiệp (Quang Huy).

- Tuần 12: Kiểm thử tích hợp luồng end-to-end (Đăng JD → Nạp GitHub → Truy xuất AST → Xếp hạng có minh chứng) trên ít nhất 1 kịch bản mẫu (Cả nhóm). Checkpoint 3 (Go/No-Go): luồng end-to-end chạy được trên 1 mẫu – nếu chưa đạt, tuần 13 cắt bớt test case.

- Tuần 13: Tuần đệm dự phòng và ổn định hệ thống – fix bug tích hợp, tối ưu độ trễ, lập bảng kịch bản kiểm thử (Test Cases), rà soát pipeline trước khi benchmark (Cả nhóm).

- Tuần 14: Chạy Benchmark RQ1 (Precision/Recall/F1@5, NDCG@5, MRR, Ragas, kiểm định Wilcoxon, Ablation study) – Quang Huy chạy, Thu An đối soát.

Giai đoạn 4 – Viết Báo cáo & Bảo vệ (Tuần 15–18):

- Tuần 15: Viết bản thảo Báo cáo chuẩn 3 chương + Mở đầu + Kết luận theo đúng mục lục; khung Slide bảo vệ sơ bộ (Quang Huy & Thu An).

- Tuần 16: Viết hoàn thiện báo cáo theo đúng phân công trong mục lục báo cáo, định dạng theo Phụ lục 1 UIT; hoàn thiện 70% Slide bảo vệ (Quang Huy & Thu An).

- Tuần 17: Rà soát chéo lỗi chính tả, chuẩn hóa trích dẫn IEEE; hoàn thiện Slide và kịch bản thuyết trình (Cả nhóm).

- Tuần 18: Quay video demo dự phòng; in ấn và nộp Báo cáo cùng Phiếu chấm điểm cho GVHD và Khoa;

Xác nhận của CBHD *(Ký tên và ghi rõ họ tên)* Ths Trần Thị Hồng Yến	**TP. HCM, ngày 06 tháng 09 năm 2026** **Sinh viên** *(Ký tên và ghi rõ họ tên)* Phạm Viết Quang Huy Nguyễn Ngọc Thu An